



深圳大學
SHENZHEN UNIVERSITY

计算机前沿技术 研究生创新示范课程研究报告

姓名：刘旺林

学号：2210273117

2023 年 2 月 6 日

基于域对抗迁移网络的电池健康度预测

刘旺林

摘要

由于锂离子电池 (LIB) 在电动汽车 (EV) 中的广泛应用, 电池用于监控 LIB 状态和保证操作安全的管理系统 (BMS) 已被广泛使用研究。充电状态 (SOC) 是在线监控的最重要的 LIB 状态之一。然而, 准确的 SOC 估计具有挑战性, 因为电池动力学不稳定且 SOC 变化电流、温度、工作条件等。在本文中, 一种自适应域对抗网络与长短期记忆网络 LSTM 的 DA-LSTM 网络。首先使用 DANN 网络提取不同数据集的公共特征, 然后应用 LSTM 网络进行预测, 从而实现准确和稳定的 SOC 估计。所提方法可以简化繁琐的参数调整过程 LSTM 网络, 并且不需要建立电池模型。从动态压力测试收集的数据是用作训练数据集, 而从 US06 测试和联邦城市驾驶时间表收集的数据用作测试数据集验证了所提方法的迁移泛化能力。实验结果表明, 与单独的 LSTM 方法和相比, DA-LSTM 对不同数据集表现出优异的泛化能力和解决初始误差的收敛能力。

关键词: 长短期记忆递归神经网络; 域对抗迁移网络

1 引言

由于迫切需要减少化石燃料消耗和温室气体排放, 开发电动汽车因其环保特性和丰富的发电能源, 如风能、太阳能、波浪能和核能, 在世界范围内引起了广泛关注。锂离子电池因其功率密度高、充电能力快、寿命长和自放电率低的优点, 被广泛应用于电动汽车的储能系统。确保电动汽车的运行安全、耐久性、可靠性和效率, 先进的电池管理系统对于及时准确地监测电池状态至关重要。充电状态 (SOC) 是指电池的剩余容量, 是 BMS 需要监测的最重要状态之一。准确、实时地估计 SOC 对于开发有效的 BMS 非常有帮助。然而, SOC 不能直接测量, 本质上取决于许多因素, 如电流、电压、温度和年龄。此外, 锂电池系统是一个高度时变和非线性系统, 因为它的动态不稳定, 这是由不同的电池材料和不同的工作条件引起的。因此, 准确获得 SOC 是一项挑战, 通常会制定估算策略, 根据电流、电压和温度等可测量信号获取 SOC 值。本次课程的论文复现工作拟通过复现长短期记忆 (LSTM) 网络与自适应域对抗网络相结合的方法。利用 LSTM 网络学习 SOC 与测量值 (包括电流、电压和温度)。最终实现准确稳定的 SOC 估计。

2 相关工作

2.1 基于深度对抗长短期记忆神经网络的负载预测

随着云计算时代的到来, 越来越多的公司将应用迁移到云计算平台上。云计算通过使用虚拟化技术将离散的资源整合成资源池, 以按需分配的方式实现了用户对计算资源的弹性需求。云计算的本质是按需求提供服务, 实现应用资源在云平台上的自动分配和切换。要实现计算能力动态伸缩需要负载均衡技术。云计算平台使用负载均衡技术增加了吞吐量, 强化了数据处理能力。负载是实现负载均衡所需要的关键指标。准确预测应用负载可以实现应用容量的流量高峰扩容和流量低谷缩容, 从而节约资源成本, 减少人工干预, 提升云计算平台的可靠性和性能。现在预测负载数据的方法有基于神经

网络的时间序列预测算法，例如循环神经网络（recurrent neural network, RNN），长短期记忆（long short-term memory, LSTM）神经网络等。神经网络类算法在时序数据预测上应用广泛。Yazdanian 等 [2] 结合卷积神经网络（convolutional neural networks, CNN）和 LSTM，预测云环境中应用未来的工作负载；谢晓兰等 [3] 使用自适应概率的多选择策略遗传算法优化 LSTM 容器云资源预测模型，取得了较高的预测精度。在云环境软件老化和抑郁症预测等其他场景下，神经网络模型取得了良好的预测效果 [4-5]。还有一类算法，例如用增强集成树算法进行破产预测 [6]，用集成学习算法提高预测模型的准确度 [7]，这类算法通常不用于时序预测问题。在时间序列预测问题上，传统的神经网络模型，例如长短期记忆网络，经常会出现过拟合的问题，从而在测试数据上表现出较大的误差。该问题我提出了基于生成式对抗网络（GAN）和长短期记忆网络（LSTM）的深度对抗长短期记忆网络，该网络可以根据两个不同时间段的数据集进行对抗训练，从而找到两个时间段的公共特征空间，再通过特征空间对应的特征向量输入长短期记忆网络（LSTM）进行预测，相比普通的神经网络，DA-LSTM 不仅不会出现过拟合问题，还取得了更高的预测精度。

3 本文方法

3.1 本文方法概述

使用神经网络预测时序数据时很容易出现过拟合问题，本文提出的深度对抗长短期记忆网络（DA-LSTM），通过生成式对抗网络找到数据的公共特征空间，再通过 LSTM 网络进行预测。由于两段数据输入进 GAN 之后输出为数据的公共特征空间，所以在对数据进行预测时不会出现对某一段数据出现过拟合的情况，同时也提高了对后续时间段的预测精度。本文预测方法的主要贡献包括：1）将深度对抗神经网络（DANN）引入负载预测；2）将传统的深度对抗神经网络（DANN）中的预测器对应的 BP 网络修改为预测精度更高的 LSTM 网络。

3.2 长短期记忆网络（LSTM）

传统的统计和数学方法在分析时间序列时需要在指定的时间窗口上运行，传统的机器学习算法需要大量的特征工程来训练分类器，LSTM 神经网络无须特征工程即可学习长期顺序特征；递归神经网络存在梯度消失的问题，使模型无法正常收敛，LSTM 解决了这一问题。基于这些优点，人们开始使用 LSTM 对时间序列建模 [18]。LSTM 是对传统递归时间神经网络的改进，使用记忆单元替换 RNN 内的隐函数，使其可以记忆比 RNN 更长的信息。LSTM 的记忆单元有 3 个控制门控，分别为输入门、遗忘门和输出门。LSTM 记忆单元结构如图 1 所示。LSTM 的模型表述如下：

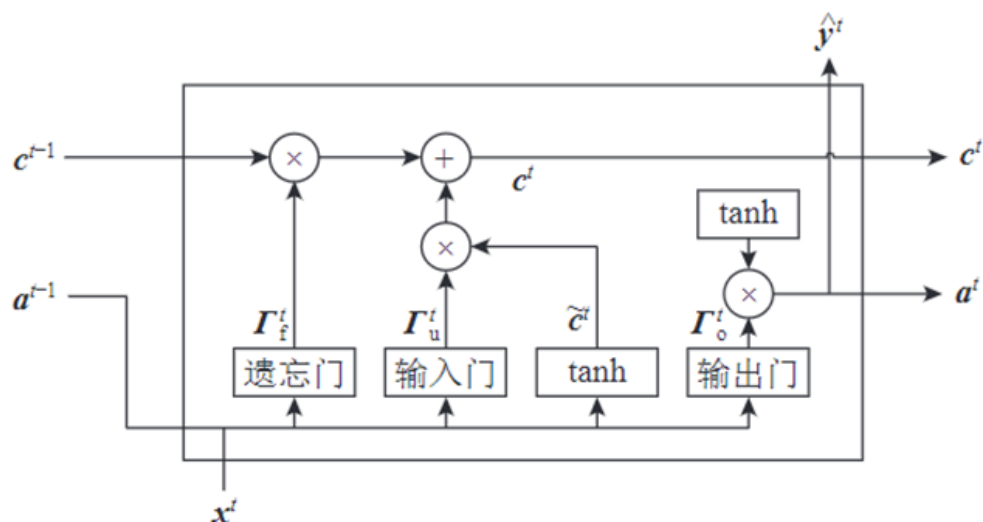


图 1: LSTM 的模型

3.3 生成式对抗网络 (GAN)

生成对抗网络其实是两个网络的组合：生成网络（Generator）负责生成模拟数据；判别网络 Discriminator）负责判断输入的数据是真实的还是生成的。生成网络要不断优化自己生成的数据让判别网络判断不出来，判别网络也要优化自己让自己判断得更准确。二者关系形成对抗，因此叫对抗网络。GAN 的整个流程如下：1、先输入真实数据让判别器学习，真实数据对应的标签是 1。2、在随机生成一个种子传入生成器生成数据让判别器学习，判别器要识别数据对应的标签为 0，即为假数据，此时 loss 不更新生成器，仅传回判别器。3、最后让生成器生成数据，将数据传给判别器，此时判别器识别数据对应标签为 1，此时的 loss 不更新判别器，更新生成器

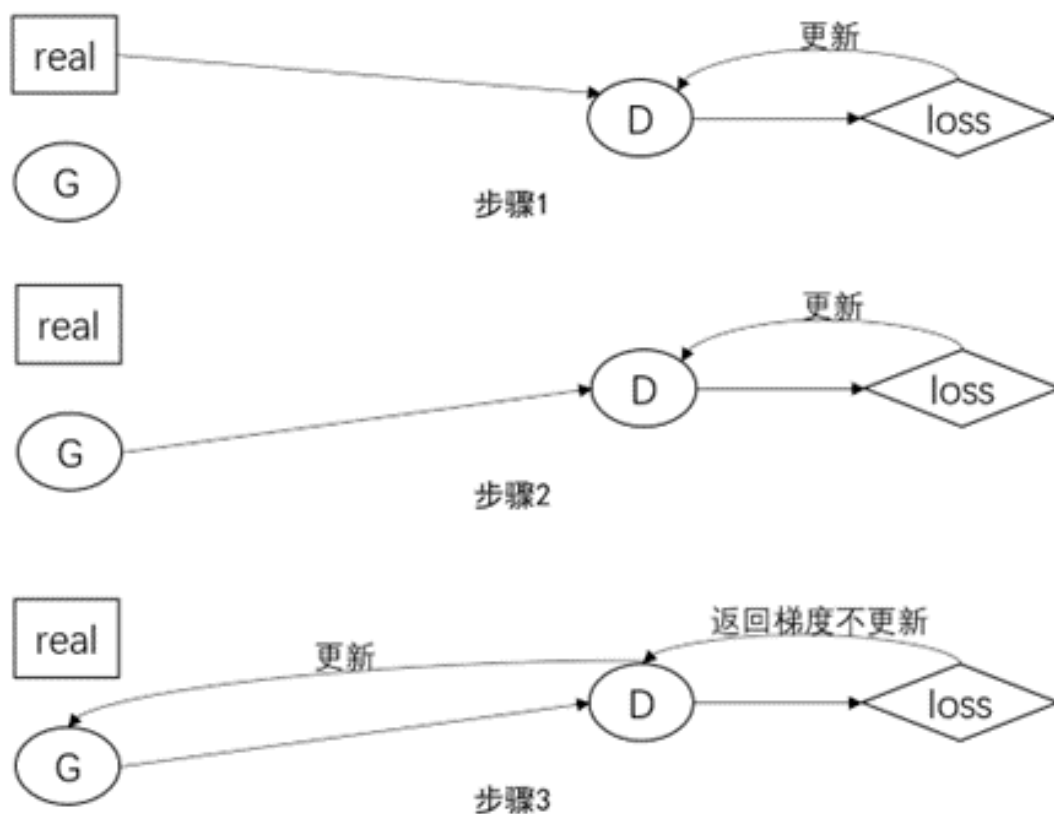


图 2: GAN 的模型

这是一个生成器和判别器博弈的过程。生成器生成假数据，然后将生成的假数据和真数据都输入判别器，判别器要判断出哪些是真的哪些是假的。判别器第一次判别出来的会有很大的误差，然后根据 loss 来优化判别器。现在判别器水平提高了，生成器生成的数据很难再骗过判别器了，所以我们得反过来优化生成器，之后生成器水平提高了，然后反过来继续训练判别器，判别器水平又提高了，再反过来训练生成器，就这样循环往复，直到达到纳什均衡。

4 深度对抗神经网络（DANN）

DANN 是一种迁移学习方法，是对抗迁移学习方法的代表方法。如图 3，DANN 基本结构由特征提取部分（左上角），分类器部分（右上角）和对抗部分（右下角）组成，其中特征提取部分和分类器部分其实就是一个标准的分类模型，通过 GAN（生成对抗网络）得到迁移对抗模型的灵感。但此时生成的不是假样本，而是假特征，一个足以让目标域和源域区分不开的假特征。而领域判别器其实是个标准的二分类分类器，0 是源域，1 是目标域。它本身的目标是区分源域和目标域，而我们想要的结果是使判别器越来越分不出数据特征来自源域还是目标域，感觉起来这很矛盾。但其实我们引入一个梯度反转层就可以完美避免这个问题。

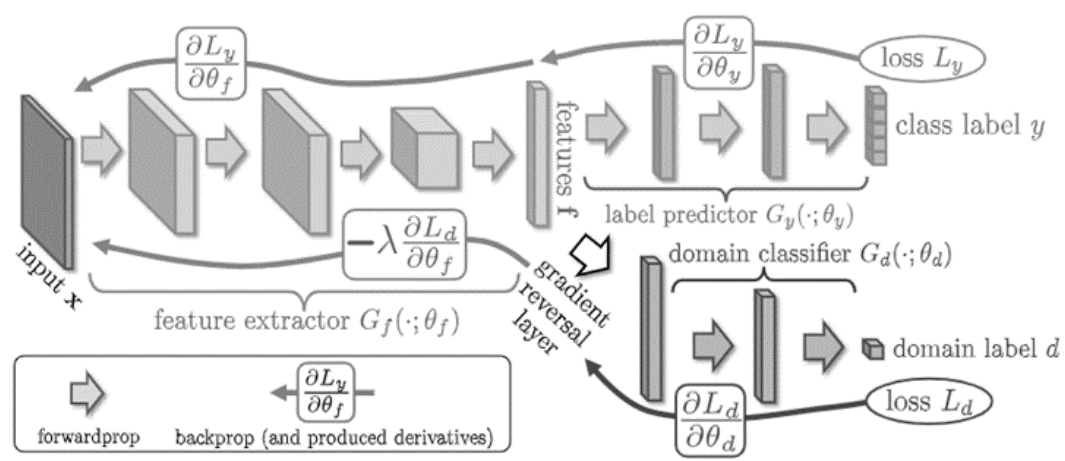


图 3: DANN 基本结构

5 梯度反转层（GRL）

域分类器与图像分类器的输入都来自与特征提取器，但是域分类器的目标是最大化域分类损失，混淆目标域数据与源域数据，但是图像分类器的目标是最小化图像分类损失，实现图像的精准分类。那么这就导致特征提取器在进行参数更新时，域分类损失的梯度与图像分类损失梯度方向相反。为了避免像 GAN 那样分别固定生成器与鉴别器参数的方式进行分阶段训练，DANN 结构中提出了全新的梯度反转层（Gradient Reversal Layer, GRL），使得在反向传播过程中梯度方向自动取反，在前向传播过程中实现恒等变换，相关数学表示如下式所示

$$R_{\lambda}(x) = x$$

$$\frac{dR_{\lambda}}{dx} = -\lambda I$$

$$\lambda_p = \frac{2}{1+\exp(-\gamma * p)} - 1$$

$$\mu_p = \frac{\mu_0}{(1+\alpha * p)^{\beta}}$$

图 4: DANN 基本结构

6 预测方法构建

6.1 DA-LSTM 预测方法主要过程

针对单一模型可能出现的问题，本文采用了深度对抗长短期记忆网络（DA-LSTM）来进行训练和预测。先将数据集进行 min-max 均值归一化对原始数据进行标准化处理，然后将输入数据组合成 x_i, y_i 的形式输入进入特征提取器，经过特征提取层的线性层、Layernorm 层、Relu 层、线性层、Layernorm 层和 Sigmoid 层输出含有八个元素的特征向量，然后将特征向量分别输入预测器和判别器。该向量输入进入鉴别器后经过线性层、Layernorm 层、Relu 层、线性层、Layernorm 层和 Sigmoid 层输出含有一个元素的类别元素，鉴别器将源域分类为标签 1，将目标域分类为标签 0，通过均方差计算出损失回传，损失训练鉴别器时不经过梯度反转层，训练时特征提取器时要经过特征反转层。该向量输入进入预测器后经过 LSTM 层、Layernorm 层、Relu 层、Drop 层、线性层和 Sigmoid 层输出含有一个元素的预测结果，结果与原数据的标签通过均方差计算出损失，直接回传训练预测器和判别器。

6.2 预测器部分改进

本文修改了 DANN 网络中预测器部分，将原有的网络修改为预测时间序列效果更好的长短期记忆网络（LSTM），并且在 LSTM 网络后添加了一个线性层，让预测结果更加准确，整个预测器模型如下图。

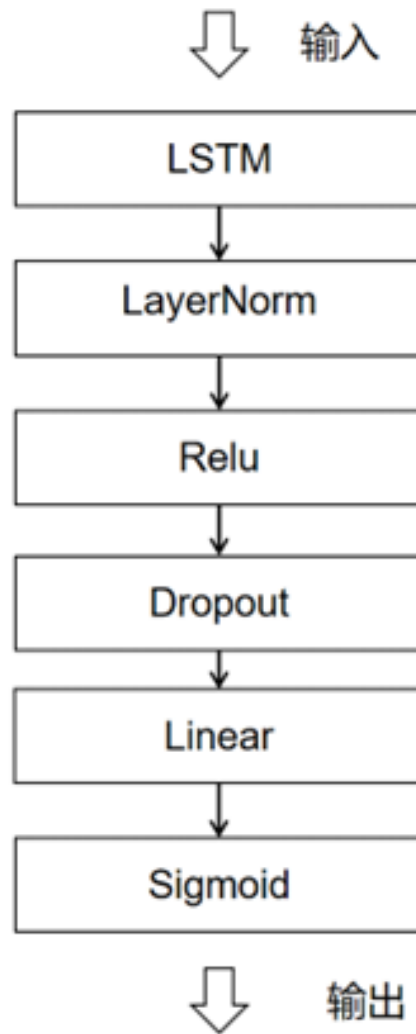


图 5: DANN 基本结构

7 实验结果分析

数据集我选用了平均充电电流降（ACCD）、平均充电电压升（ACVR）、充电电压饱和时间（STCV）、等压充电时间（EVCT）这四项数据作为特征来预测容量，下表为四个特征与 B5，B6 和 B7 电池容量的 Pearson 相关性，从表格可以看出四个特征与容量的相关性都很强利用在规定的 4000s 和 5000s 的时间间隔范围内 100 个电流来定义平均充电电流降（ACCD）。




图 6: 数据集提取

长短期记忆网络（LSTM）预测器的预测结果

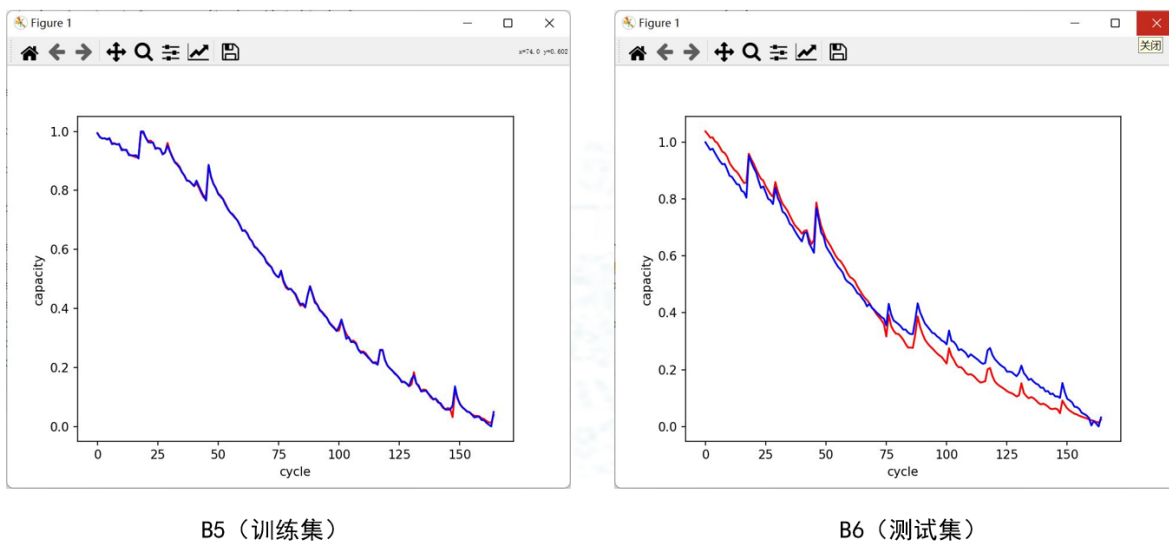


图 7: B5,B6 组电池训练集

域自适应对抗网络（DANN）预测结果




图 8: DA-LSTM 预测结果

8 总结与展望

针对常用时序预测算法过拟合和迁移性差的问题，提出基于深度对抗长短期记忆神经网络的负载预测，提高了应用负载预测的迁移能力，而且减少了过拟合情况。对三组电池的负载预测也有较高的精度，较准确地预测出了负载周期性变化，验证了方法的有效性和执行效率。算法可以对负载进行更为准确的预测，为应用的实时调控提供更为可信的决策依据，有利于提升应用支撑平台的性能和可靠性。目前算法训练耗时较长，未来可以通过优化特征提取网络结构或者使用注意力机制的方法提高预测精度。

9 总结与展望

YAZDANIAN P, SHARIFIAN S. Cloud workload prediction using ConvNet and stacked LSTM [C]// 2018 4th Iranian Conference on Signal Processing and Intelligent Systems. Tehran: IEEE, 2018: 83–87. [3] 谢晓兰, 张征征, 郑强清, 等. 基于 APMSSGA-LSTM 的容器云资源预测 [J]. 大数据, 2019, 5(6): 62–72. XIE Xiao-lan, ZHANG Zheng-zheng, ZHENG Qiang-qing, et al. Container cloud resource prediction based on APMSSGA-LSTM [J]. Big Data Research, 2019, 5(6): 62–72. [4] LIU J, TAN X Y, WANG Y. CSSAP: software aging prediction for cloud services based on ARIMA-LSTM hybrid model [C]// 2019 IEEE International Conference on Web Services. Milan: IEEE, 2019: 283–290. [5] KUMAR S D, SUBHA

D P. Prediction of depression from EEG signal using long short term memory [C]// 2019 3rd International Conference on Trends in Electronics and Informatics. Tirunelveli: IEEE, 2019: 1248–1253. [6] ZIĘBA M, TOMCZAK S K, TOMCZAK J M. Ensemble boosted trees with synthetic features generation in application to bankruptcy prediction [J]. Expert Systems with Applications, 2016, 58: 93–101. [7] AKYUZ A O, UYSAL M, BULBUL B A, et al. Ensemble approach for time series analysis in demand forecasting: Ensemble learning [C]// 2017 IEEE International Conference on Innovations in Intelligent Systems and Applications. Gdynia: IEEE, 2017: 7–12. [8] 蔡亮, 周泓岑, 白恒. 基于多层 BiLSTM 和改进粒子群算法的应用负载预测方法 [A]. 浙江宁波: 浙江大学学报, 2020, 54(12):2414-2422.]